

Gruppo di lavoro

- Michele_Loconte, matricola 741221, m.loconte27@studenti.uniba.it

AA 2025-2026

CLASSIFICAZIONE AUTOMATICA DI NUMERI

Introduzione

Il progetto ha come obiettivo la classificazione automatica delle immagini di numeri scritti a mano, in una griglia di 8x8 pixel.(per un totale di 64 feature)

Rientra nell' apprendimento automatico dove vengono analizzati e confrontati i 3 modelli usati: Decision Tree , Support Vector Machine, K-Nearest Neighbors.

Sommario

E' un sistema di apprendimento automatico supervisionato che apprende dal dataset "load_digits" incluso nella libreria scikit-learn che contiene circa 1797 sample di numeri scritti a mano .

Quindi in fase di addestramento vengono fornite le feature di input (64pixel "appiattiti") e le classi target corrispondenti (i numeri da 0 a 9)

Apprendimento Supervisionato (Classificazione , Modelli di base e valutazione)

La base di conoscenza è rappresentata dal dataset standard digits di Scikit-learn, suddiviso in feature (data, array di 64 elementi) e target (target, valori da 0 a 9). I modelli di ragionamento e apprendimento adottati per risolvere il problema di classificazione multiclasse sono l'Albero di Decisione, la Support Vector Machine (SVC) e il K-Nearest Neighbors (KNN).

La complessità delle regole per l'Albero di Decisione è limitata a una profondità massima pari a (max_depth=20), riducendo il rischio di overfitting e limitando la complessità del ragionamento a un massimo di 20 controlli sequenziali sui pixel.

Strumenti utilizzati

-la libreria pylab viene usata per la generazione dei grafici;

- DecisionTreeClassifier per l'albero di decisione
- SVC per la Support Vector Machine
- KNeighborsClassifier per il KNN
- GridSearchCV per la ricerca dei parametri migliori;
- cross_validate per la valutazione con validazione incrociata.

Decisioni di Progetto

Per evitare il bias di campionamento e rendere più affidabili le valutazioni dei modelli da scelte arbitrarie, le predizioni vengono calcolate tramite la tecnica Nested Cross Validation con Outer CV a 5-Fold (per la stima dell' errore) e Inner CV a 3-Fold(per l' ottimizzazione) su tutti i modelli, al fine di garantire dei test su un modello addestrato sull' 80% dei dati.

I 3 modelli sono configurati tramite i best parameters dati calcolati dalla GridSearchCV come segue:

SVC: C=1 e kernel='linear';

KNN: analizza i 3 vicini più prossimi (n_neighbors=3);

Albero di decisione: profondità massima max_depth=20 e min_samples_split=2.

Valutazione

I report sono generati dalle iterazioni di 5-Fold Cross Validation adottando le seguenti metriche:

REPORT METRICHE (KNN) [Nested 5-Fold CV]

Precision: 0.967 ($\pm$ 0.008)

Recall: 0.965 ($\pm$ 0.009)

F1-Score: 0.965 ($\pm$ 0.009)

REPORT METRICHE (SVC) [Nested 5-Fold CV]

Precision: 0.950 ($\pm$ 0.021)

Recall: 0.948 ($\pm$ 0.021)

F1-Score: 0.947 ($\pm$ 0.021)

REPORT METRICHE (ALBERO DI DECISIONE) [Nested 5-Fold CV]

Precision: 0.802 ($\pm$ 0.037)

Recall: 0.794 ($\pm$ 0.043)

F1-Score: 0.791 ($\pm$ 0.045)

Area Under Curve (Decision Tree): 0.794

Area Under Curve (SVM): 0.961

Area Under Curve (KNN): 0.988

Conclusioni

Il progetto permette di confrontare 3 modelli , che usano lo stesso dataset per identificare un numero senza l'uso di Computer Vision o Deep learning ma trattando il problema come una classificazione su vettori .

Dai dati ricevuti dai vari test si nota come KNN e SVC abbiano prestazioni migliori rispetto agli alberi di decisioni e infatti restituiscono previsioni più affidabili .

Tramite la Nested Cross validation si è risolto il problema dell' overfitting dimostrando che i modelli hanno capacità di generalizzare.

In futuro sarebbe opportuno ampliare i caratteri riconosciuti o utilizzare dataset più complessi confrontando sempre le performance.

Riferimenti Bibliografici

[1] Scikit-learn Developers: *Machine Learning in Python*. Documentazione ufficiale dei moduli `sklearn.svm`, `sklearn.tree`, `sklearn.neighbors` e `sklearn.metrics`.

[2] N. Fanizzi, "Ingegneria della Conoscenza", Dispensa del Corso di Laurea in Informatica,